

2026 금융 AI Challenge 기능 명세서

팀명	GODknows	구성원 성명	고동영
----	----------	--------	-----

(* 필수항목)

1. MVP 구현 범위 *

합성 시나리오·통화·거래 탐지·경량 RAG/RRF·정탐/오탐·Mock/Ollama Local/5개 Cloud Provider를 구현했습니다. 로컬 P1은 Next → FastAPI → 실제 LangGraph 병렬 fan-out/fan-in → Ollama qwen2.5:7b → guarded_policy/Safety → InMemorySaver 멀티턴을 지원합니다.

실시간 STT·거래 스트림·금융사 레거시·실제 신고/지급정지·개인정보 저장은 구현 범위에 포함하지 않았습니다.

2. 주요 기능 목록 *

F01 샘플재생, F02 위험탐지, F03 거래결합, F04 경량 RAG/RRF Top3, F05 Provider 라우터, F06 allowlist guarded_policy, F07 규칙 Safety/폴백, F08 실제 LangGraph trace, F09 session 멀티턴, F10 응답 투명성, F11 합성 회귀평가 — 모두 구현을 완료했습니다.

공개 P0는 배포 URL에서 Mock과 Cloud BYOK를 실행합니다. 로컬 P1은 localhost의 Ollama-FastAPI-Next 3개 프로세스에서 실행하며 공개 서버는 사용자 PC의 Ollama에 접근할 수 없습니다.

3. 사용자 이용 흐름 *

공개: URL → Mock → 합성 시나리오 → simulated flow·위험·거래·검색 근거 확인.

로컬: ollama serve → FastAPI :8000 → Next :3000 → Ollama Local 선택 → 질문 → actual trace-session-turn-guarded_policy를 확인합니다.

4. AI 및 데이터 처리 방식 *

FastAPI ChatState 저장 후 `transaction_signal_agent`가 통화와 독립적으로 거래 이상신호를 만들고, `structured_risk_agent`가 규칙 판정과 구조화 Qwen 판정을 융합한 뒤 `knowledge_agent·policy_agent`를 병렬 실행해 `ollama_generate`로 fan-in하고 `safety_verifier·alert_planner`를 거쳐 반환합니다(총 9 Node, Qwen 호출 2회). Qwen은 실제 호출되지만 자유문은 폐기하며 서버 allowlist가 `guarded_policy`를 구성하고 규칙 기반 Safety 검사를 거쳐 반환합니다.

입력은 합성 통화 문장·거래 신호·질문입니다. 출력은 위험도·이유·서버 선택 검색 근거·정책 행동·`response_mode·trace`입니다. 38건 회귀셋과 40건 고정 홀드아웃은 회귀평가 기준선이며 실사용 성능을 주장하는 수치가 아닙니다. 처음 보는 표현으로 평가한 독립 블라인드 40건에서는 2026-08-14 기준 Macro F1 40.5%로 떨어졌고, 이 일반화 한계를 데모 4번 시나리오에서 미탐으로 그대로 재현합니다.

실제 개인정보와 계좌정보는 저장하지 않습니다. 로컬 Qwen 자유문은 State-API-UI 어디에도 남기지 않습니다. Cloud BYOK는 React state와 Next 1회 요청을 경유하며 앱 저장 기능은 없지만 호스팅 사업자와 Provider의 로그 정책은 별개입니다.

5. MVP 검증 방법 *

공개 URL에서 Mock 기관사칭·완곡표현 미탐·정상 Hard Negative를 실행해 위험·거래·검색 근거를 비교합니다. 완곡표현 시나리오는 같은 수법이라도 규칙 어휘를 피하면 통화 탐지가 실패함을 보여주고, 그 때도 백그라운드 거래 신호가 단독으로 경보를 만드는 이중 트랙을 확인합니다. 실제 Qwen은 로컬에서 Ollama → FastAPI → Next를 실행하고 Ollama Local 선택 후 actual trace와 `guarded_policy`를 확인합니다.

Mock 모드는 계정이 필요하지 않습니다. '안전계좌로 즉시 이체'는 위험, '지금 송금할 필요 없음'은 정상으로 판정합니다. 피해발생 응답은 1394·긴급 시 112·해당 금융회사 연락·지급정지 요청을 모두 포함합니다. Cloud Provider를 쓸 때만 사용자 API 키가 필요합니다.

최신 Chrome-Edge-Safari를 권장합니다. 로컬 P1은 Ollama `qwen2.5:7b·Python FastAPI :8000·Next :3000`이 필요합니다. 검증은 `npm test`(Windows는 `npm run test:win`), `pytest`, `smoke_ollama.py`로 수행합니다.

프론트·백엔드 자동검사와 동일 session 2턴 smoke를 통과했습니다. 모든 데이터와 수치는 소형 합성 회귀 기준선입니다. 실제 사기 확정·거래차단·1394/112 신고·금융회사 지급정지는 수행하지 않고, 실시간 처리·개인정보·감사·기관 연동은 P2 범위입니다.

※ 용어 설명 — 본문에 쓰인 기술 용어를 풀어 씁니다.

P0 / P1 / P2 : 구현 우선순위입니다. P0은 공개 데모, P1은 로컬 실제 모델 데모, P2는 이번 범위에서 제외한 향후 과제입니다.

Mock : 외부 서비스나 API 키 없이 같은 입력에 항상 같은 결과를 내는 내장 시연 모드입니다.

BYOK : 심사위원이 본인의 API 키를 직접 입력해 실제 모델을 호출하는 방식입니다. 키는 저장하지 않습니다.

LangGraph / Node : 처리 단계를 그래프로 연결해 실행하는 구조이며, Node는 그 한 단계입니다.

병렬 fan-out / fan-in : 여러 단계를 동시에 실행한 뒤 결과를 한곳에 모으는 방식입니다.

RAG : 답변에 앞서 관련 근거 문서를 먼저 찾아오는 방식입니다.

RRF : 서로 다른 검색 순위를 하나로 합쳐 최종 순위를 정하는 방법입니다.

guarded_policy : 모델이 만든 문장을 그대로 쓰지 않고, 서버가 미리 허용한 안내 문장만 골라 답변하는 안전 장치입니다.

allowlist : 미리 허용한 항목만 사용하도록 제한한 목록입니다.

정탐 / 오탐 / 미탐 : 정탐은 위험을 옳게 찾은 경우, 오탐은 정상을 위험이라 잘못 본 경우, 미탐은 위험을 놓친 경우입니다.

Hard Negative : 위험해 보이는 단어가 있지만 실제로는 정상인 사례로, 오탐을 걸러내는지 확인하는 시험 문항입니다.

Macro F1 : 위험과 정상 두 부류를 똑같이 중요하게 보고 계산한 종합 정확도 지표입니다.

회귀셋 / 홀드아웃 / 블라인드 : 회귀셋은 이미 고친 문제의 재발을 보는 시험지, 홀드아웃은 따로 떼어 둔 시험지, 블라인드는 개발 중 한 번도 보지 않은 새 문장으로 보는 시험지입니다.

trace : 실제로 어떤 단계를 거쳐 결과가 나왔는지 기록한 실행 이력입니다.

STT : 통화 음성을 글자로 바꾸는 기술이며 이번 범위에서는 사용하지 않았습니다.

1394 / 지급정지 : 1394는 보이스피싱 24시간 통합신고·상담 번호이고, 지급정지는 송금된 돈이 인출되지 않도록 계좌를 묶는 조치입니다.